

Avaliação dos Modelos de Previsão

Uma Abordagem Métrica Centrada

Versão 1.0

Alexandre Soares



Avaliação dos Modelos de Previsão

Uma Abordagem Métrica Centrada

por

Alexandre Soares

Conteúdo

1	Introdução	1
2	Contexto	2
2.1	Descrevendo o Cenário	2
2.2	Estratégia Usada para Construção dos Modelos	2
2.2.1	Considerações sobre a Estratégia de duas Equipes	3
3	Sobre os Dados	4
3.1	Dados Utilizados	4
4	Principais Métricas Utilizadas	6
4.1	Métricas Utilizadas Neste Estudo	6
4.2	Sobre Erro Médio Absoluto (MAE)	8
4.2.1	A Equação do Erro Médio Absoluto	8
4.2.2	Atributos Principais do MAE	9
4.3	Sobre Erro Médio Quadrático (RMSE)	10
4.3.1	A Equação do Erro Médio Absoluto	10
4.3.2	Atributos Principais do RMSE	11
4.4	Sobre Erro Percentual Absoluto Médio (MAPE)	12
4.4.1	A Equação do Erro Percentual Absoluto Médio	12
4.4.2	Atributos Principais do MAPE	13
4.5	Sobre Erro Percentual Absoluto Médio Simétrico (SMAPE)	14
4.5.1	A Equação do Erro Percentual Absoluto Médio	14
4.5.2	Atributos Principais do SMAPE	15
4.6	Sobre Erro Percentual Absoluto Mediano (MDAPE)	15
4.6.1	A Equação do Erro Percentual Absoluto Mediano	16
4.6.2	Atributos Principais do MDAPE	16
4.7	Sobre Erro Absoluto Relativo Médio Geométrico (GMRAE)	17
4.7.1	A Equação do Erro Percentual Absoluto Mediano	17
4.7.2	Atributos Principais do GMRAE	18
5	Resultados Obtidos	19
5.1	Resultados da Primeira Equipe	19
5.2	Resultados da Segunda Equipe	21
6	Quais Métricas Utilizar para Avaliação dos Resultados	22
6.1	Quando Usar o MAE	22
6.1.1	Vantagens e Desvantagens do MAE	23
6.2	Quando Usar o RMSE	24
6.2.1	Vantagens e Desvantagens do RSME	25
6.3	Critério de Decisão entre MAE e RSME	26
6.4	Quando Usar o MAPE	27
6.4.1	Vantagens e Desvantagens do MAPE	27
6.5	Quando Usar o SMAPE	28
6.5.1	Vantagens e Desvantagens do SMAPE	28
6.6	Critério de Decisão entre MAPE e SMAPE	29
6.7	Quando Usar o MDAPE	30
6.7.1	Vantagens e Desvantagens do MDAPE	30

6.8	Quando Usar o GMARAE	31
6.8.1	Vantagens e Desvantagens do GMRAE	31
6.9	Critério de Decisão entre MDAPE e GMARAE	32
7	Conclusão	33
7.1	Resumo Geral	33
7.1.1	Resultados Obtidos pelos Grupos de Desenvolvimento	34

Lista de Figuras

3.1	Apresentação dos Dados	4
4.1	Modelos Possíveis para Medir a Precisão	6
5.1	Comportamento da Previsão do Primeiro Grupo	20
5.2	Comportamento da Previsão do Segundo Grupo	21
6.1	Critério de Decisão entre MAE e RSME	26
6.2	Critério de Decisão entre MAPE e SMAPE	29
6.3	Critério de Decisão entre MDAPE e GMARAE	32

Lista de Tabelas

3.1	Detalhamento dos Campos da Base de Dados	4
4.1	Principais Métricas Utilizadas	7
4.2	Entendimento do Nome Atribuído - MAE	8
4.3	Atributos Principais do MAE	9
4.4	Entendimento do Nome Atribuído - RMSE	10
4.5	Atributos Principais do RMSE	11
4.6	Entendimento do Nome Atribuído - MAPE	12
4.7	Atributos Principais do MAPE	13
4.8	Entendimento do Nome Atribuído - SMAPE	14
4.9	Atributos Principais do SMAPE	15
4.10	Entendimento do Nome Atribuído - MDAPE	15
4.11	Atributos Principais do MDAPE	16
4.12	Entendimento do Nome Atribuído - GMRAE	17
4.13	Atributos Principais do GMRAE	18
6.1	Recomendação para o uso da métrica MAE	22
6.2	Vantagens e Desvantagens do MAE	23
6.3	Recomendação para o uso da métrica RMSE	24
6.4	Vantagens e Desvantagens do RSME	25
6.5	Recomendação para o uso da métrica MAPE	27
6.6	Vantagens e Desvantagens do MAPE	27
6.7	Recomendação para o uso da métrica SMAPE	28
6.8	Vantagens e Desvantagens do SMAPE	28
6.9	Recomendação para o uso da métrica MDAPE	30
6.10	Vantagens e Desvantagens do MDAPE	30
6.11	Recomendação para o uso da métrica GMARAE	31
6.12	Vantagens e Desvantagens do GMRAE	31
7.1	Resultados das Métricas Calculadas	34

1

Introdução

Uma série temporal é definida como um conjunto ordenado no tempo de diversas observações de uma variável específica. Essa ordenação cronológica revela padrões não aleatórios da variável de interesse, permitindo a identificação de tendências e comportamentos passados. Com essas informações, podemos realizar previsões sobre o futuro, orientando uma tomada de decisões baseada em dados.

Além de identificar padrões não aleatórios, a análise de séries temporais busca detectar um sistema causal relativamente constante. A observação desse comportamento passado auxilia no desenvolvimento de modelos capazes de prever o futuro.

A estimativa do futuro, realizada por meio de modelos preditivos, é fundamental para entender os resultados alcançados. A avaliação desses valores deve ser baseada em métricas que descrevam a precisão, a confiabilidade e a eficácia obtidas.

Essa abordagem permite a melhoria e o ajuste dos parâmetros do modelo utilizado para a previsão, garantindo a qualidade dos métodos empregados e eliminando potenciais problemas. Além disso, maximiza as oportunidades de tomada de decisão estratégica e otimiza os recursos e investimentos em análises preditivas.

2

Contexto

2.1. Descrevendo o Cenário

Uma empresa de venda de carros deseja prever suas vendas futuras e reestruturar toda a organização com base nessas previsões. Com os resultados obtidos, a empresa planeja implementar novos planos de contratação, uma política de bônus atualizada e uma estratégia de marketing reformulada.

2.2. Estratégia Usada para Construção dos Modelos

Como observado na seção anterior, este modelo de previsão terá um grande impacto na empresa e deverá ser o mais exato possível. Para garantir esse resultado, foi decidido que a construção dos modelos de previsão será desenvolvida por duas equipes distintas, e, por meio das métricas, será escolhido o melhor modelo.

A primeira equipe, liderada por especialistas em aprendizado de máquina, optou por desenvolver um modelo baseado em algoritmos de aprendizado de máquina. Eles estão focados em descobrir as nuances sutis nos padrões de compra dos clientes, aproveitando grandes conjuntos de dados históricos.

A segunda equipe, composta por economistas e estatísticos, usa uma abordagem mais tradicional. Eles se concentram em técnicas estatísticas robustas e teorias econômicas para descobrir os fatores fundamentais que influenciam o comportamento do consumidor.

2.2.1. Considerações sobre a Estratégia de duas Equipes

Essa estratégia de utilizar duas equipes de desenvolvimento permite que cada grupo organize suas próprias habilidades e metodologias. Assim, uma equipe pode se concentrar na abordagem centrada no aprendizado de máquina, enquanto a outra usa diversas teorias estatísticas e econômicas tradicionais. Isso aumenta a diversidade de perspectivas e melhora a modelagem.

Com isso, a empresa cria uma redundância, aumentando a robustez de suas previsões ao ter dois modelos independentes. Um modelo pode ser substituído por outro para corrigir seus erros, diminuindo o perigo de depender demasiadamente de um único modelo.

Essa abordagem permite usar comparações cruzadas para validar os resultados dos dois modelos, garantindo que sejam consistentes e confiáveis em diferentes situações.

Dessa forma, a empresa incentiva a inovação e o aprendizado contínuo ao fomentar uma competição saudável entre as duas equipes, garantindo a captura e diversidade de perspectivas, redundância, validação cruzada e estímulo à inovação.

3

Sobre os Dados

3.1. Dados Utilizados

O conjunto de dados "Vendas Mensais de Carros" está disponível no formato CSV, amplamente utilizado para armazenar informações tabulares. Este conjunto de dados consiste em duas variáveis principais, conforme apresentado na Tabela-3.1.

Descrição dos Campos	
Variável	Descrição
Mês	Indica o mês em que ocorreram as vendas de carros.
Vendas	Indica o número total de carros vendidos no mês.

Tabela 3.1: Detalhamento dos Campos da Base de Dados

Os dados apresentam uma entrada mensal, permitindo uma análise das tendências de vendas ao longo do tempo, como mostrado na Figura-3.1.




Figura 3.1: Apresentação dos Dados

Este conjunto de dados é amplamente utilizado para análises e previsões de tendências de vendas, ajudando os profissionais a entender melhor os padrões de compra dos consumidores e a criar planos de marketing, além de apoiar a tendência de vendas.

Os dados estão disponibilizados no repositório GitHub¹ e são consumidos diretamente pelo comando de leitura do pandas na linguagem Python.

¹<https://raw.githubusercontent.com/jbrownlee/Datasets/master/monthly-car-sales.csv>

Principais Métricas Utilizadas

4.1. Métricas Utilizadas Neste Estudo

A precisão e qualidade obtidas pelos modelos de predição podem ser avaliadas por uma variedade de métricas. Este trabalho se restringe às métricas apresentadas na Figura-4.1.

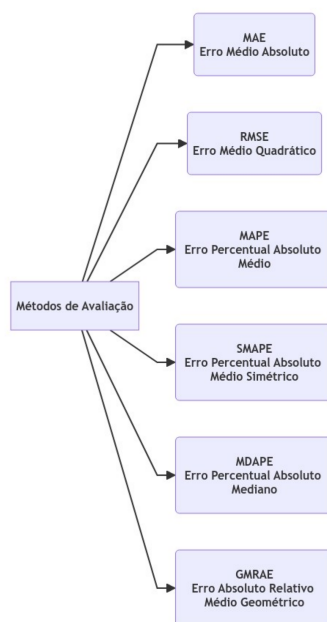


Figura 4.1: Modelos Possíveis para Medir a Precisão

A Tabela-4.1, apresenta de maneira resumida a descrição das métricas utilizadas neste estudo.

Conjunto de Métricas	
Métrica	Descrição
Erro Médio Absoluto (MAE)	O MAE é uma métrica simples que calcula a média das diferenças absolutas entre as previsões do modelo e os valores reais, fornecendo uma medida direta do tamanho médio dos erros, independente da direção.
Erro Médio Quadrático (RMSE)	O RMSE é uma medida que penaliza os erros maiores de forma mais acentuada do que erros menores. A métrica calcula a raiz quadrada da média dos quadrados das diferenças entre as previsões do modelo e os valores reais, fornecendo uma indicação da dispersão dos erros.
Erro Percentual Absoluto Médio (MAPE)	O MAPE é uma métrica que expressa o erro como uma porcentagem do valor real. Para tanto, calcula a média das diferenças percentuais absolutas entre as previsões do modelo e os valores reais, proporcionando uma medida de precisão relativa.
Erro Percentual Absoluto Médio Simétrico (SMAPE)	O SMAPE é uma versão simétrica do MAPE, que considera a magnitude relativa dos valores previstos e reais, calculando a média das diferenças percentuais absolutas, mas usando a média dos valores previstos e reais no denominador, tornando-o menos sensível a valores extremos.
Erro Absoluto Relativo Médio (MDAPE)	O MDAPE é uma métrica que calcula a mediana das diferenças percentuais absolutas entre as previsões do modelo e os valores reais, fornecendo uma medida robusta da precisão do modelo, especialmente em situações onde valores extremos dos dados podem distorcer a interpretação da precisão média.
Erro Absoluto Relativo Médio Geométrico (GMRAE)	O GMRAE é uma medida que calcula a média geométrica das diferenças relativas absolutas entre as previsões do modelo e os valores reais, fornecendo uma medida robusta da precisão do modelo, sendo desta forma menos sensível a valores extremos nos dados.

Tabela 4.1: Principais Métricas Utilizadas

Os cientistas de dados utilizam essas métricas para avaliar e comparar os resultados obtidos pelos modelos preditivos. Essas aferições contribuem com informações importantes sobre a qualidade das previsões, além de apoiar escolhas conscientes sobre o desempenho dos modelos utilizados na predição.

4.2. Sobre Erro Médio Absoluto (MAE)

O Erro Médio Absoluto (MAE), também conhecido como Mean Absolute Error em inglês, é uma métrica comumente utilizada na avaliação de modelos de previsão ou regressão. Esta métrica quantifica a média das diferenças absolutas entre os valores observados e os valores previstos pelo modelo.

Buscando o entendimento a partir do nome atribuído à métrica, é descrito na Tabela-4.2 o entendimento das partes que a definem, contribuindo assim para um melhor entendimento.

Entendimento do Nome Atribuído	
Nome	Descrição
Erro	O termo erro refere-se à discrepância entre os valores previstos pelo modelo e os valores reais observados nos dados. Quando um modelo faz uma previsão, é comum que haja uma diferença entre essa previsão e a realidade. O objetivo desta medida é minimizar esse erro tanto quanto possível para que as previsões sejam precisas e úteis.
Médio	O termo médio indica que estamos calculando uma média. Ou seja, o MAE considera a média dos erros em todas as previsões feitas pelo modelo. Isso é importante porque nos dá uma medida agregada do desempenho do modelo em todo o conjunto de dados, em vez de apenas olhar para um erro específico em uma única previsão.
Absoluto	O termo absoluto significa que estamos interessados apenas na magnitude das diferenças entre os valores previstos e os valores reais, sem se preocupar com a direção dessas diferenças. Ao tomar o valor absoluto de cada erro, garantimos que tanto os erros positivos quanto os negativos contribuam igualmente para o cálculo do MAE.

Tabela 4.2: Entendimento do Nome Atribuído - MAE

4.2.1. A Equação do Erro Médio Absoluto

A fórmula para calcular o Erro Médio Absoluto (MAE), apresentada na Equação-4.1 é relativamente simples e direta. Ela envolve calcular a média das diferenças absolutas entre os valores previstos \hat{Y}_i e os valores reais Y_i :

$$MAE = \frac{1}{n} \sum_{i=1}^n |Y_i - \hat{Y}_i| \quad (4.1)$$

onde:

- n é o número total de observações no conjunto de dados de teste.
- Y_i é o valor real observado para a i -ésima observação.
- \hat{Y}_i é o valor previsto pelo modelo para a i -ésima observação.
- $|Y_i - \hat{Y}_i|$ é a diferença absoluta entre o valor real e o valor previsto para a i -ésima observação.
- \sum indica a soma sobre todas as observações no conjunto de teste.

4.2.2. Atributos Principais do MAE

O Mean Absolute Error (MAE) é uma métrica de avaliação comum, normalmente utilizada para medir a magnitude média dos erros em previsões numéricas.

Ao considerar esses atributos, apresentados na Tabela-4.3, o MAE pode ser uma escolha apropriada dependendo das características específicas do problema e das preferências em relação à interpretabilidade e robustez aos outliers.

Atributos Principais	
Atributo	Descrição
Interpretabilidade	O MAE é facilmente interpretável, pois representa a média absoluta das diferenças entre os valores observados e os valores previstos.
Robustez	O MAE é robusto a outliers, isso significa que um único valor extremo não afetará muito o MAE, tornando-o uma escolha melhor em situações onde outliers são uma preocupação.
Sensibilidade à escala	O MAE é sensível à escala dos dados. Por exemplo, se os valores de entrada estiverem em escalas muito diferentes, o MAE não dará uma noção clara da magnitude do erro em relação aos dados.
Ponderação uniforme	O MAE atribui o mesmo peso para todos os erros, independentemente da magnitude do valor verdadeiro. Isso pode ser uma vantagem ou desvantagem, dependendo do contexto do problema.
Facilidade de cálculo	O MAE é fácil de calcular, exigindo apenas a diferença absoluta entre os valores observados e previstos, tornando-o computacionalmente eficiente.
Métrica intuitiva	A interpretação direta do MAE como a média das diferenças absolutas o torna intuitivo e fácil de explicar para pessoas não técnicas, como partes interessadas ou clientes.

Tabela 4.3: Atributos Principais do MAE

4.3. Sobre Erro Médio Quadrático (RMSE)

O Erro Médio Quadrático (RMSE), em inglês Root Mean Square Error, é amplamente utilizada na avaliação de modelos de previsão ou regressão. Esta métrica mede a média da magnitude dos erros ao quadrado entre os valores previstos pelo modelo e os valores reais observados nos dados.

Buscando o entendimento a partir do nome atribuído à métrica, é descrito na Tabela-4.4 o entendimento das partes que a definem, contribuindo assim para um melhor entendimento.

Entendimento do Nome Atribuído	
Nome	Descrição
Erro	O termo <i>Erro</i> refere-se à discrepância entre os valores previstos pelo modelo e os valores reais observados nos dados. Quando um modelo faz uma previsão, é comum que haja uma diferença entre essa previsão e a realidade.
Médio	O termo <i>médio</i> no RMSE indica que estamos calculando uma média. Ou seja, estamos interessados na média dos erros ao quadrado.
Quadrático	Ao contrário do MAE, que usa diferenças absolutas, o RMSE calcula a média dos erros ao quadrado. Isso significa que erros maiores são penalizados de forma mais acentuada do que erros menores. O objetivo disso é ampliar a importância dos erros maiores, dando ao modelo uma retroalimentação mais forte sobre a precisão das previsões.
Raiz Quadrada	Depois de calcular a média dos erros ao quadrado, o RMSE aplica a raiz quadrada para retornar à mesma escala que os valores originais, fornecendo uma interpretação mais intuitiva do erro em termos das unidades dos dados originais.

Tabela 4.4: Entendimento do Nome Atribuído - RMSE

4.3.1. A Equação do Erro Médio Absoluto

A equação para calcular o Erro Médio Quadrático (RMSE), ou Root Mean Square Error em inglês, apresentada na Equação-4.2 é relativamente simples.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2} \quad (4.2)$$

onde:

- n é o número total de observações no conjunto de dados de teste.
- Y_i é o valor real observado para a i -ésima observação.
- \hat{Y}_i é o valor previsto pelo modelo para a i -ésima observação.
- $(Y_i - \hat{Y}_i)^2$ é o quadrado da diferença entre o valor real e o valor previsto para a i -ésima observação.
- \sum indica a soma sobre todas as observações no conjunto de teste.
- $\sqrt{}$ é a operação de raiz quadrada, aplicada ao resultado da soma dos quadrados das diferenças, para retornar à mesma escala que os valores originais.

4.3.2. Atributos Principais do RMSE

Portanto, o RMSE é uma medida importante para avaliar o desempenho dos modelos de previsão ou regressão, pois fornece uma medida da dispersão dos erros entre os valores reais dos dados e os preditos pelo modelo. Seus atributos são descritos na Tabela-4.5.

Atributos Principais	
Atributo	Descrição
Interpretação da escala	O RMSE é representado na mesma unidade dos dados originais. Por exemplo, o RMSE será em dólares se estivermos prevendo vendas em dólares. Como o RMSE está na mesma escala dos valores que estamos tentando prever, é fácil de interpretar.
Erro quadrático médio	O RMSE calcula a média das diferenças quadráticas entre os valores reais e as previsões do modelo. Isso indica que o RMSE prioriza erros significativos em comparação com erros menores. Quando queremos penalizar mais fortemente previsões muito imprecisas, isso pode ser útil.
Comparativamente com o MAE	Embora o RMSE e o MAE (Erro Médio Absoluto) sejam medidas de erro semelhantes, eles não tratam os erros da mesma forma. Enquanto o MAE trata todos os erros de forma uniforme, o RMSE é mais sensível a erros significativos. Se houver preocupações com erros significativos, o uso do RMSE pode ser mais vantajoso em determinadas circunstâncias.
A referência à precisão do modelo	O desempenho do modelo é melhor quando o valor do RMSE é menor. Um RMSE de zero indica uma correspondência perfeita entre os valores reais e as previsões do modelo, o que é raro na prática. Portanto, é fundamental considerar o RMSE no contexto do problema em questão, bem como o desempenho de diferentes modelos.
Uma comparação dos modelos	A métrica RMSE é útil para comparar o desempenho de vários modelos. A maioria das pessoas prefere um modelo com um RMSE menor porque indica que suas previsões estão mais próximas dos valores reais. No entanto, considerações adicionais, como a interpretabilidade e a complexidade do modelo, devem ser levadas em conta.

Tabela 4.5: Atributos Principais do RMSE

4.4. Sobre Erro Percentual Absoluto Médio (MAPE)

O Erro Percentual Absoluto Médio (MAPE), em inglês Mean Absolute Percentage Error, é uma métrica comumente usada para avaliar a precisão de modelos de previsão ou regressão, especialmente em contextos onde a magnitude dos erros é importante em relação aos valores reais.

Buscando o entendimento a partir do nome atribuído à métrica, é descrito na Tabela-4.6 o entendimento das partes que a definem, contribuindo assim para um melhor entendimento.

Entendimento do Nome Atribuído	
Nome	Descrição
Erro Percentual Absoluto	O termo <i>Erro Percentual Absoluto</i> refere-se à discrepância entre os valores previstos pelo modelo e os valores reais observados nos dados, como em outras métricas de erro. O "erro percentual absoluto" é a diferença absoluta entre o valor previsto e o valor real, expressa como uma porcentagem do valor real. Isso significa que o MAPE mede o tamanho relativo do erro em relação ao valor real.
Média	Como o nome sugere, o MAPE calcula a média dos erros percentuais absolutos em todas as previsões feitas pelo modelo. Isso proporciona uma medida agregada do desempenho do modelo em todo o conjunto de dados, permitindo uma compreensão geral de sua precisão.
Percentual	O MAPE é expresso como uma porcentagem, o que facilita a interpretação e comparação do desempenho do modelo. Uma porcentagem mais baixa indica um MAPE menor e, portanto, uma maior precisão do modelo em fazer previsões.

Tabela 4.6: Entendimento do Nome Atribuído - MAPE

4.4.1. A Equação do Erro Percentual Absoluto Médio

A equação para calcular o Erro Percentual Absoluto Médio (MAPE), é apresentada pela Equação-4.3.

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{Y_i - \hat{Y}_i}{Y_i} \right| \times 100\% \quad (4.3)$$

onde:

- n é o número total de observações no conjunto de dados de teste.
- Y_i é o valor real observado para a i -ésima observação.
- \hat{Y}_i é o valor previsto pelo modelo para a i -ésima observação.
- $\left| \frac{Y_i - \hat{Y}_i}{Y_i} \right|$ é o erro percentual absoluto para a i -ésima observação, expresso como uma porcentagem do valor real.
- \sum indica a soma sobre todas as observações no conjunto de teste.
- $\times 100\%$ converte o resultado final em uma porcentagem.

4.4.2. Atributos Principais do MAPE

O Erro Percentual Absoluto Médio (MAPE) é uma métrica comum usada para avaliar a precisão de previsões, expressando o erro como uma porcentagem da magnitude dos valores reais. Na Tabela-4.7 são apresentados os principais atributos.

Atributos Principais	
Atributo	Descrição
Interpretabilidade	Assim como o MAE, o MAPE é facilmente interpretável, pois representa a média das porcentagens absolutas das diferenças entre os valores observados e os valores previstos.
Robustez	O MAPE não é tão robusto quanto o MAE em relação a outliers. Como os erros são expressos como porcentagens, valores extremos podem distorcer significativamente o MAPE, especialmente quando os valores reais estão próximos de zero.
Sensibilidade à escala	O MAPE é sensível à escala dos dados, uma vez que é uma medida relativa. Isso significa que ele pode ser usado para comparar a precisão entre diferentes modelos ou conjuntos de dados, mas pode ser difícil de interpretar em termos absolutos, especialmente quando os valores reais estão próximos de zero ou são muito pequenos.
Incorporação natural da magnitude dos valores	Ao expressar o erro como uma porcentagem dos valores reais, o MAPE naturalmente leva em consideração a magnitude dos valores reais, o que pode ser útil em contextos onde a escala dos valores é importante.
Facilidade de interpretação	O MAPE é fácil de interpretar, especialmente em termos de porcentagem de erro em relação aos valores reais. Isso o torna útil para a comunicação com partes interessadas não técnicas.
Limitações com valores próximos a zero	Uma desvantagem do MAPE é que ele não é bem definido quando os valores reais são zero ou próximos de zero, já que a divisão por zero é impossível. Isso pode ser um problema em certos contextos, como previsões de demanda onde podem ocorrer valores zero.

Tabela 4.7: Atributos Principais do MAPE

4.5. Sobre Erro Percentual Absoluto Médio Simétrico (SMAPE)

Uma métrica comumente usada para avaliar a precisão de modelos de previsão ou regressão é o Erro Percentual Absoluto Médio Simétrico (SMAPE), que considera a magnitude dos erros em relação aos valores reais. Isso é particularmente útil em situações em que os valores reais e previstos podem estar muito próximos de zero ou quando os valores variam significativamente.

Buscando o entendimento a partir do nome atribuído à métrica, é descrito na Tabela-4.8 o entendimento das partes que a definem, contribuindo assim para um melhor entendimento.

Entendimento do Nome Atribuído	
Nome	Descrição
Erro Percentual Absoluto Médio	O SMAPE calcula a média dos erros percentuais absolutos para todas as previsões feitas pelo modelo, semelhante ao MAPE (Erro Percentual Absoluto Médio). Isso fornece uma avaliação geral do desempenho do modelo no conjunto de dados.
Simétrico	O SMAPE é simétrico, o que o distingue do MAPE. A métrica é menos sensível a valores extremos ou inconsistentes porque leva em consideração a magnitude relativa dos valores reais e previstos.

Tabela 4.8: Entendimento do Nome Atribuído - SMAPE

4.5.1. A Equação do Erro Percentual Absoluto Médio

A equação para calcular o Sobre Erro Percentual Absoluto Médio Simétrico (SMAPE), é apresentada pela Equação-4.4.

$$SMAPE = \frac{1}{n} \sum_{i=1}^n \frac{|Y_i| + |\hat{Y}_i|}{(|Y_i| + |\hat{Y}_i|)/2} |Y_i - \hat{Y}_i| \quad (4.4)$$

onde:

- n é o número total de observações no conjunto de dados de teste.
- Y_i é o valor real observado para a i -ésima observação.
- \hat{Y}_i é o valor previsto pelo modelo para a i -ésima observação.
- $|Y_i - \hat{Y}_i|$ é o erro absoluto entre o valor previsto e o valor real.
- \sum indica a soma sobre todas as observações no conjunto de teste.

4.5.2. Atributos Principais do SMAPE

O SMAPE é capaz de fornecer uma medida simétrica dos erros percentuais absolutos, tornando-o mais confiável em relação a valores extremos. Ele oferece uma análise direta da precisão do modelo em relação aos valores reais. Os atributos principais são apresentados na Tabela 4.9.

Atributos Principais	
Atributo	Descrição
Valores sensíveis a zero	Quando os valores reais ou previstos estão próximos de zero, o SMAPE é particularmente útil porque evita problemas de divisão por zero que podem ocorrer em outras métricas de erro percentual.
Interpretação direta	O SMAPE é mostrado em porcentagem, o que facilita a interpretação e a comparação do desempenho do modelo.
Simetria	O SMAPE leva em consideração a média das magnitudes relativas dos valores reais e previstos, o que significa que é simétrico. Isso aumenta sua confiabilidade quando os dados contêm valores extremos ou discrepâncias.

Tabela 4.9: Atributos Principais do SMAPE

4.6. Sobre Erro Percentual Absoluto Mediano (MDAPE)

O Erro Percentual Absoluto Mediano (MDAPE) é uma métrica usada para avaliar a precisão de modelos de previsão ou regressão. Esta medida calcula a mediana das diferenças percentuais absolutas entre os valores previstos e os valores reais.

A mediana é escolhida ao invés da média para tornar o resultado menos sensível a valores extremos ou discrepantes nos dados. Buscando o entendimento a partir do nome atribuído, é descrito na Tabela 4.10 o entendimento das partes que a definem, contribuindo assim para um melhor entendimento.

Entendimento do Nome Atribuído	
Nome	Descrição
Erro Percentual Absoluto	O erro percentual absoluto refere-se à diferença percentual entre os valores previstos e os valores reais. É calculado como a diferença absoluta entre o valor previsto e o valor real, dividida pelo valor real.
Mediano	Ao contrário da média, que é a soma de todas as observações dividida pelo número de observações, a mediana é o valor do meio de um conjunto de dados ordenado. Usar a mediana torna o MDAPE menos sensível a valores extremos nos dados, tornando-o mais robusto.

Tabela 4.10: Entendimento do Nome Atribuído - MDAPE

4.6.1. A Equação do Erro Percentual Absoluto Mediano

A equação para calcular o Erro Percentual Absoluto Mediano (MDAPE), é apresentada pela Equação-4.5.

$$MDAPE = Mediana \left(\frac{|Y_i - \hat{Y}_i|}{Y_i} \right) \times 100\% \quad (4.5)$$

onde:

- Y_i é o valor real observado para a i-ésima observação.
- \hat{Y}_i é o valor previsto pelo modelo para a i-ésima observação.
- $|Y_i - \hat{Y}_i|$ é o erro absoluto entre o valor previsto e o valor real.
- *Mediana* denota a mediana das diferenças percentuais absolutas entre os valores previstos e os valores reais.
- $\times 100\%$ é usado para expressar o MDAPE como uma porcentagem.

4.6.2. Atributos Principais do MDAPE

O MDAPE calcula a mediana das diferenças percentuais absolutas que ocorrem entre os valores previstos e os valores reais, fornecendo assim uma medida robusta da precisão do modelo, especialmente em situações onde valores extremos nos dados podem distorcer a interpretação da precisão média. Seus principais atributos são apresentados na Tabela-4.11

Atributos Principais	
Atributo	Descrição
Utilização	O MDAPE é comumente usado em situações onde a precisão mediana é preferida sobre a precisão média, especialmente quando há preocupações com valores extremos nos dados.
Interpretação	Assim como outras métricas de erro percentual, o MDAPE é expresso como uma porcentagem, o que facilita a interpretação e a comparação entre modelos.
Robustez	A mediana é menos sensível a valores extremos nos dados do que a média, tornando o MDAPE mais robusto em relação a outliers.

Tabela 4.11: Atributos Principais do MDAPE

4.7. Sobre Erro Absoluto Relativo Médio Geométrico (GMRAE)

O Erro Absoluto Relativo Médio Geométrico (GMRAE) é uma métrica usada para avaliar a precisão de modelos de previsão ou regressão. É calculada a média geométrica das diferenças relativas absolutas entre os valores reais e previstos. A média geométrica é uma medida de tendência central mais sensível do que a média aritmética aos valores extremos dos dados.

Buscando o entendimento a partir do nome atribuído à métrica, é descrito na Tabela-4.12 o entendimento das partes que a definem, contribuindo assim para um melhor entendimento.

Entendimento do Nome Atribuído	
Nome	Descrição
Erro Absoluto Relativo	O erro absoluto relativo é a diferença percentual absoluta entre os valores previstos e os valores reais. Ele é calculado como a diferença absoluta entre o valor previsto e o valor real, dividido pelo valor real.
Média Geométrica	A média geométrica é uma medida de tendência central que é calculada multiplicando todos os valores e depois tirando a raiz enésima do produto, onde n é o número total de observações. Usar a média geométrica torna o GMRAE menos sensível a valores extremos nos dados, tornando-o mais robusto.

Tabela 4.12: Entendimento do Nome Atribuído - GMRAE

4.7.1. A Equação do Erro Percentual Absoluto Mediano

A equação para calcular o Erro Absoluto Relativo Médio Geométrico (GMRAE), é apresentada pela Equação-4.6.

$$GMRAE = \left(\prod_{i=1}^n |Y_i - \hat{Y}_i| \right)^{\frac{1}{n}} \times 100\% \quad (4.6)$$

onde:

- Y_i é o valor real observado para a i-ésima observação.
- \hat{Y}_i é o valor previsto pelo modelo para a i-ésima observação.
- $|Y_i - \hat{Y}_i|$ é o erro absoluto entre o valor previsto e o valor real.
- \prod denota o produto dos valores absolutos relativos dos erros para todas as observações.
- $\frac{1}{n}$ é usado para calcular a média geométrica.
- $\times 100\%$ é usado para expressar o GMRAE como uma porcentagem.

4.7.2. Atributos Principais do GMRAE

O GMRAE fornece uma avaliação confiável da precisão do modelo, especialmente quando os valores extremos dos dados podem distorcer a interpretação da precisão média. Seus principais atributos são apresentados na Tabela Tabela-4.13.

Atributos Principais	
Atributo	Descrição
Robustez	O GMRAE é mais robusto em relação a outliers porque a média geométrica é menos sensível a valores extremos nos dados do que a média aritmética.
Interpretação	O GMRAE é expresso em porcentagem, como outras métricas de erro percentual, o que facilita a interpretação e a comparação de modelos.
Uso	O GMRAE é usado quando se deseja uma métrica de erro que forneça uma medida geral de precisão do modelo e seja robusta a valores extremos.

Tabela 4.13: Atributos Principais do GMRAE

5

Resultados Obtidos

5.1. Resultados da Primeira Equipe

O gráfico apresentado na Figura-5.1 compara os valores obtidos pelo modelo desenvolvido pela primeira equipe com os valores reais e previstos ao longo do tempo. Nesta representação, podemos observar algumas características importantes:

- **Tendência geral:** A linha de valores previstos segue a tendência geral dos valores reais, indicando que o modelo conseguiu capturar a sazonalidade e o padrão de crescimento das vendas ao longo do tempo.
- **Discrepâncias:** É possível observar algumas discrepâncias entre os valores previstos e os valores reais em alguns pontos específicos da série temporal. Essas discrepâncias podem indicar que o modelo não foi capaz de capturar com precisão todos os fatores que influenciam o volume de vendas em determinados momentos.
- **Precisão:** A amplitude das discrepâncias entre os valores previstos e os valores reais varia ao longo do tempo. Em alguns momentos, as previsões são bastante precisas, enquanto em outros momentos, a discrepância é maior.




Figura 5.1: Comportamento da Previsão do Primeiro Grupo

Com base na análise visual e nas considerações acima, podemos concluir que o modelo XGB Regressor obteve um desempenho satisfatório na previsão do volume de vendas. No entanto, é importante ressaltar que ainda há espaço para aprimoramento do modelo.

5.2. Resultados da Segunda Equipe

O gráfico apresentado na Figura-5.2 compara os valores obtidos pelo modelo desenvolvido pela segunda equipe com os valores reais e previstos ao longo do tempo. Nesta representação, podemos notar algumas características importantes:

- **Tendência geral:** A linha de valores previstos segue a tendência geral da linha de valores reais, indicando que o modelo conseguiu capturar a sazonalidade e o padrão de crescimento das vendas ao longo do tempo.
- **Precisão:** A amplitude da faixa de previsão em torno da linha de valores previstos indica o nível de incerteza das previsões. Em alguns momentos, a faixa de previsão é estreita, o que indica que o modelo está mais confiante em suas previsões. Em outros momentos, a faixa de previsão é mais ampla, o que indica que o modelo está menos confiante em suas previsões.
- **Pontos fora da curva:** É possível observar alguns pontos fora da curva, ou seja, pontos em que os valores reais se distanciam significativamente da linha de valores previstos. Esses pontos podem indicar que o modelo não foi capaz de capturar com precisão todos os fatores que influenciam o volume de vendas em determinados momentos.




Figura 5.2: Comportamento da Previsão do Segundo Grupo

Podemos concluir, com base na análise visual e nas considerações acima, que o modelo Prophet fez uma previsão satisfatória do volume de vendas. O modelo capturou o padrão de crescimento das vendas e a sazonalidade ao longo do tempo, e as previsões estão dentro de um nível aceitável de incerteza. É importante lembrar que ainda há espaço para melhorias no modelo.

6

Quais Métricas Utilizar para Avaliação dos Resultados

6.1. Quando Usar o MAE

Em muitos casos, o MAE é a melhor opção, pois oferece uma interpretação direta do erro médio, sendo considerado robusto na presença de outliers. Seu cálculo é simples e de fácil interpretação. A Tabela-6.1 fornece de modo estruturado as indicações de uso.

Consideração de Uso	Descrição
Interpretação Direta do Erro Médio	Fornecer uma medida direta e intuitiva do erro médio do modelo.
Influência Controlada de Outliers	O MAE não é sensível a outliers da mesma forma que o RMSE, o que significa que os outliers não têm uma influência excessiva nos resultados. Isso é valioso em situações onde é necessário mitigar o impacto de valores extremos nos resultados da avaliação do modelo.
Penalidade Moderada por Grandes Erros	Ao contrário do RMSE, o MAE não penaliza grandes erros de forma acentuada. Isso é apropriado em contextos onde uma penalidade mais suave por grandes erros é desejável, como em problemas onde alguns erros grandes são toleráveis ou esperados.
Penalidade Moderada por Grandes Erros	Em contraste com o RMSE, o MAE não penaliza grandes erros de forma acentuada. Isso é apropriado em contextos onde uma penalidade mais suave por grandes erros é desejável, como em problemas onde alguns erros grandes são toleráveis ou esperados.
Distribuição Aproximadamente Normal dos Erros	Quando a distribuição dos erros é aproximadamente normal, o MAE pode ser preferível devido à sua robustez contra desvios na distribuição dos erros. Ele fornece uma medida estável do erro médio, independentemente de pequenas variações na distribuição dos erros.
Simplicidade de Cálculo	O MAE é mais simples de calcular e requer menos recursos computacionais do que o RMSE. Isso é particularmente relevante em situações onde o tempo de cálculo é uma preocupação, tornando o MAE uma escolha eficiente em termos de recursos.
Interpretação Direta dos Resultados	Em casos onde a interpretação direta dos resultados é uma prioridade, o MAE oferece uma medida clara e fácil de entender do desempenho do modelo, contribuindo para uma comunicação mais clara e transparente dos resultados.
Tratamento Similar de Erros Pequenos e Grandes	O MAE trata erros pequenos e grandes de forma similar, o que pode ser preferível em situações onde não há uma distinção clara entre a importância relativa de diferentes tamanhos de erros.

Tabela 6.1: Recomendação para o uso da métrica MAE

6.1.1. Vantagens e Desvantagens do MAE

Como consideração final, segue de maneira estruturada, conforme apresentado na Tabela-6.2 as vantagens e desvantagens a serem observadas ao escolher esta métrica:

Erro Médio Absoluto (MAE)	
⊕ Vantagens	⊖ Desvantagens
Fácil de entender, pois fornece uma medida direta da precisão da previsão.	Não penaliza erros grandes de maneira severa, o que pode ser uma limitação em casos em que erros grandes são mais críticos.
Os valores do erro estão nas mesmas unidades dos dados originais, tornando-os interpretáveis.	Trata a superestimação e subestimação de forma igual.
Menos sensível a outliers em comparação com outras métricas.	Não fornece informações sobre a variabilidade dos erros, apenas sua média
O cálculo é direto e não requer operações complexas.	

Tabela 6.2: Vantagens e Desvantagens do MAE

6.2. Quando Usar o RMSE

Em várias situações, o RMSE pode ser considerado a melhor opção, uma vez que essa métrica fornece uma avaliação mais abrangente do desempenho do modelo em comparação com o MAE, especialmente em situações em que a distribuição dos erros, a variação dos erros e a presença de outliers são importantes. A Tabela-6.2 apresenta as indicações de uso de forma estruturada.

Consideração de Uso	Descrição
Penalização da Variância dos Erros	O RMSE penaliza a variância dos erros de forma mais acentuada. Isso significa que o RMSE oferece uma medida mais sensível ao desempenho do modelo quando a variação nos erros é considerada crucial, como em aplicações em que uma mudança mínima nos resultados pode ter um grande impacto.
Tratamento Rigoroso de Outliers	O RMSE trata outliers com mais rigor do que o Erro Absoluto Médio (MAE). Outliers podem distorcer a interpretação dos resultados ou levar a decisões incorretas, por isso o RMSE é especialmente importante em situações como essas.
Punição Severa de Grandes Erros	O RMSE é melhor do que o MAE em situações em que grandes erros são considerados inaceitáveis ou têm consequências graves.
Distribuição Não Normal dos Erros	O RMSE ainda fornece uma avaliação confiável do desempenho do modelo em situações em que os dados de erro não são normalmente distribuídos. Ele é melhor para uma variedade de situações de modelagem porque é menos sensível a distribuições assimétricas ou não normais do que o MAE.
Prioridade na Precisão do Modelo e Otimização do Ajuste aos Dados	Quando a precisão do modelo é essencial e o ajuste dos dados deve ser otimizado, o RMSE é particularmente útil. Isso se deve ao fato de que o RMSE se concentra mais nos erros significativos, o que pode resultar em um ajuste mais preciso dos parâmetros do modelo em relação aos dados observados.
Tratamento Diferenciado de Erros Pequenos e Grandes	O RMSE é melhor para alguns casos, como na detecção de anomalias ou em problemas em que erros grandes e pequenos têm impactos diferentes. Isso se deve ao fato de que ele reflete melhor a importância relativa desses erros.
Conhecimento da Distribuição dos Erros	O RMSE pode ser mais apropriado em situações em que a distribuição dos erros é conhecida e segue uma distribuição normal. Isso ocorre porque ele é derivado diretamente da variância dos erros, o que facilita a interpretação dos resultados.

Tabela 6.3: Recomendação para o uso da métrica RMSE

6.2.1. Vantagens e Desvantagens do RSME

Como consideração final, segue, de maneira estruturada, conforme apresentado na Tabela-6.4 as vantagens e desvantagens a serem observadas ao escolher esta abordagem:

Erro Médio Absoluto (RSME)	
⊕ Vantagens	⊖ Desvantagens
Ao elevar os erros ao quadrado, são penalizados os erros maiores de forma mais significativa do que erros menores.	É sensível a outliers, ou seja, valores extremos podem distorcer significativamente o resultado
Fornece uma medida da dispersão dos erros, não apenas sua média	Pode ser menos intuitivo para leigos entenderem a significância prática do resultado.
Embora não seja tão intuitivo quanto o MAE, mas ainda é facilmente interpretável, pois o resultado está na mesma escala que os dados originais.	Como os erros são elevados ao quadrado, o RMSE trata os erros positivos e negativos de forma simétrica.

Tabela 6.4: Vantagens e Desvantagens do RSME

6.3. Critério de Decisão entre MAE e RSME

O fluxograma apresentado na Figura-6.1, estrutura um roteiro de perguntas que auxilia a decisão de qual métrica utilizar, esta escolha passa a ser baseada em um processo de decisão simples e efetivo.

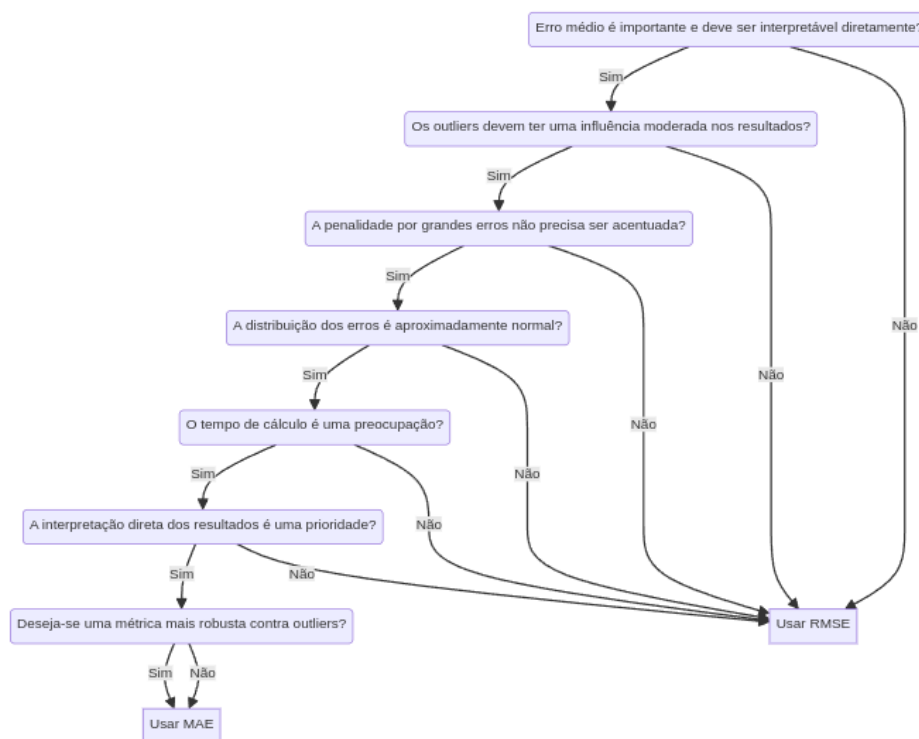


Figura 6.1: Critério de Decisão entre MAE e RSME

6.4. Quando Usar o MAPE

O MAPE é uma métrica útil para uma ampla gama de situações, em particular na avaliação da precisão de modelos de previsão, bem como na interpretação direta do erro percentual e na comparação de modelos com diferentes escalas. A Tabela-6.5 fornece de modo estruturado as indicações de uso.

Consideração de Uso	Descrição
Avaliação de Modelos de Previsão	O MAPE é frequentemente usado para avaliar a precisão de modelos de previsão, especialmente em setores como finanças, economia e planejamento de demanda, onde a precisão das previsões é vital.
Interpretação Direta do Erro Percentual	O MAPE fornece uma medida direta e fácil de entender da precisão percentual das previsões em relação aos valores reais. Ao mostrar o erro como uma porcentagem da variável de interesse, ele facilita a interpretação do desempenho do modelo.
Comparação de Modelos com Diferentes Escalas	O MAPE normaliza o erro em relação aos valores reais, tornando-o útil para comparar o desempenho de vários modelos ou métodos de previsão que operam em escalas diferentes.
Robustez contra Valores Nulos	O MAPE é adequado para conjuntos de dados onde há observações ausentes ou valores nulos, pois é resistente a esses valores.
Priorização da Precisão Percentual	O MAPE é preferível quando a precisão percentual é mais importante do que a precisão absoluta, pois enfatiza a precisão relativa das previsões.
Modelagem de Séries Temporais	O MAPE é amplamente utilizado no modelamento de séries temporais para avaliar a precisão de previsões de curto e médio prazo, como previsão de vendas.
Avaliação da Precisão em Percentual	O MAPE fornece uma medida direta e informativa do desempenho do modelo quando a avaliação da precisão das previsões em termos de porcentagem de erro é uma prioridade.

Tabela 6.5: Recomendação para o uso da métrica MAPE

6.4.1. Vantagens e Desvantagens do MAPE

Como consideração final, segue, de maneira estruturada, conforme apresentado na Tabela-6.6 as vantagens e desvantagens a serem observadas ao escolher esta abordagem:

Erro Percentual Absoluto Médio (MAPE)	
⊕ Vantagens	⊖ Desvantagens
Fornece uma medida direta da precisão das previsões em termos percentuais, facilitando a interpretação do desempenho do modelo	Os resultados podem ser influenciado por outliers, especialmente quando os valores são extremos.
É uma métrica adimensional, o que significa que é independente da escala dos dados.	No entanto, os resultados podem ser influenciados por outliers, especialmente quando os valores são extremos.
O cálculo é direto e não requer operações complexas.	É altamente sensível a valores zero ou próximos a zero.

Tabela 6.6: Vantagens e Desvantagens do MAPE

6.5. Quando Usar o SMAPE

O Erro Percentual Absoluto Médio Simétrico (SMAPE) é útil em vários cenários de previsão, especialmente quando é necessário considerar a simetria dos erros percentuais e quando se deseja uma métrica de avaliação confiável e fácil de entender da precisão das previsões. A Tabela-6.7 fornece de modo estruturado as indicações de uso.

Consideração de Uso	Descrição
Previsão em Séries Temporais	O SMAPE é particularmente útil para avaliar modelos de previsão em séries temporais, como previsões de vendas, demanda de produtos ou tráfego na web, onde a simetria dos erros percentuais é importante.
Robustez contra Valores Nulos	O SMAPE é adequado para conjuntos de dados que não têm observações ou valores faltantes porque é robusto contra valores nulos.
Interpretação Direta do Erro Percentual	O SMAPE, assim como o MAPE, fornece uma medida fácil de entender e direta da precisão percentual das previsões em relação aos valores reais, facilitando a interpretação do desempenho do modelo.
Equilíbrio entre Erros de Subestimação e Superestimação	O SMAPE fornece uma visão mais equilibrada da precisão das previsões porque leva em conta tanto os erros de subestimação quanto os de superestimação.
Comparação de Modelos com Diferentes Escalas	O SMAPE, assim como o MAPE, é útil para comparar o desempenho de vários modelos ou métodos de previsão que operam em escalas diferentes, pois normaliza o erro em relação aos valores reais.
Priorização da Precisão Percentual Simétrica	O SMAPE oferece uma medida simétrica da precisão das previsões, o que o torna mais vantajoso em situações em que é necessário considerar tanto os erros de subestimação quanto os erros de superestimação.

Tabela 6.7: Recomendação para o uso da métrica SMAPE

6.5.1. Vantagens e Desvantagens do SMAPE

Como consideração final, segue, de maneira estruturada, conforme apresentado na Tabela-6.8 as vantagens e desvantagens a serem observadas ao escolher esta abordagem:

Erro Percentual Absoluto Médio Simétrico (SMAPE)	
⊕ Vantagens	⊖ Desvantagens
Ao contrário do MAPE, o SMAPE evita problemas de divisão por zero quando os valores reais são zero, pois adiciona um termo de suavização.	Muito embora evite problemas de divisão por zero quando os valores reais são zero, ele ainda pode ser sensível a valores próximos de zero.
Fornece uma medida direta da precisão das previsões em termos percentuais, tornando os resultados facilmente interpretáveis.	Dificuldade para comparar diretamente com outras métricas de avaliação, especialmente aquelas que não são baseadas em porcentagem.
Trata os erros positivos e negativos de forma simétrica, o que significa que ele considera tanto a subestimação quanto a superestimação de forma equivalente.	Pode produzir resultados inconsistentes em casos específicos, especialmente quando os valores reais e as previsões são ambos zero.

Tabela 6.8: Vantagens e Desvantagens do SMAPE

6.6. Critério de Decisão entre MAPE e SMAPE

Escolher entre MAPE (Mean Absolute Percentage Error) e SMAPE (Symmetric Mean Absolute Percentage Error) para avaliar a precisão de modelos de previsão depende de vários fatores. O fluxograma apresentado na Figura-6.2, estrutura um roteiro de perguntas, que auxilia a decisão de qual métrica utilizar.

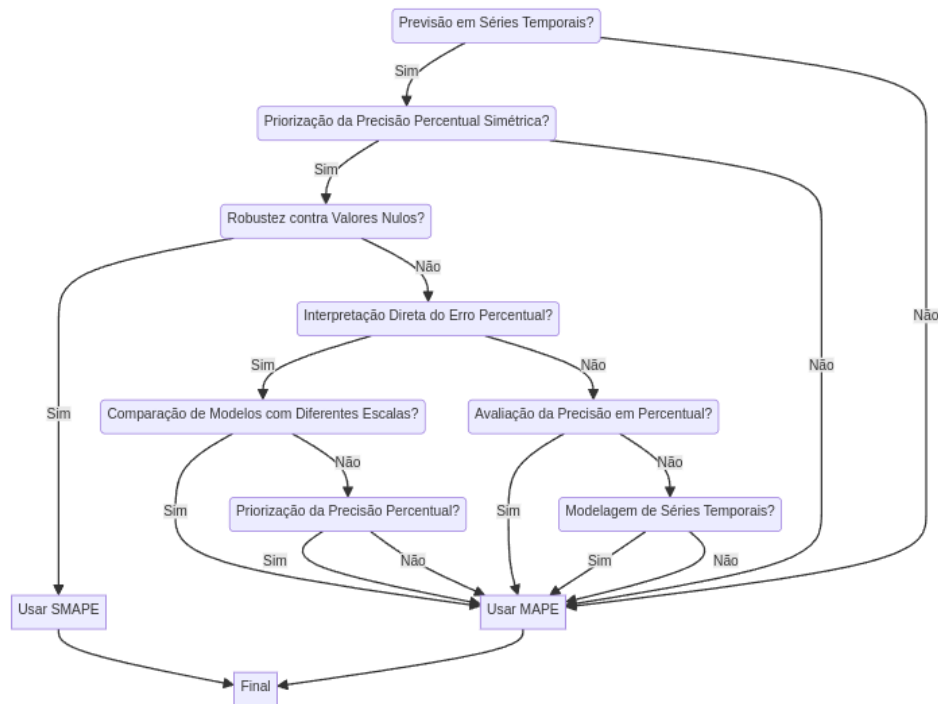


Figura 6.2: Critério de Decisão entre MAPE e SMAPE

6.7. Quando Usar o MDAPE

O MDAPE (Erro Percentual Absoluto Médio Direcional) é uma medida útil, indicada para situações em que a direção dos erros de previsão é significativa. A Tabela-6.9 fornece de modo estruturado as indicações de uso.

Consideração de Uso	Descrição
Previsão Direcional	Quando os erros de previsão são tão significativos quanto a direção deles, prever corretamente se o preço de um ativo aumentará ou diminuirá é essencial no mercado financeiro.
Priorização da Direcionalidade	Se você quiser enfatizar a precisão da direção das previsões em vez de apenas a magnitude dos valores previstos, isso é particularmente crucial quando as decisões são tomadas com base nas previsões.
Modelagem de Tendências	Em contextos onde a identificação correta de tendências é fundamental, como previsão de vendas, tráfego ou demanda, o MDAPE pode ser preferível, pois avalia a precisão na direção das mudanças.
Avaliação de Modelos em Séries Temporais	O MDAPE pode ser usado para avaliar a precisão dos modelos em séries temporais, especialmente nos casos em que a direcionalidade das previsões é mais importante do que a magnitude dos valores previstos.
Robustez contra Valores Nulos	O MDAPE, como outras métricas de erro percentual, é resistente a valores nulos nos dados. Isso o torna adequado para conjuntos de dados onde há observações ausentes ou valores faltantes.

Tabela 6.9: Recomendação para o uso da métrica MDAPE

6.7.1. Vantagens e Desvantagens do MDAPE

Como consideração final, segue, de maneira estruturada, conforme apresentado na Tabela-6.10 as vantagens e desvantagens a serem observadas ao escolher esta abordagem:

Erro Percentual Absoluto Médio Direcional (MDAPE)	
⊕ Vantagens	⊖ Desvantagens
O cálculo é direto e não requer operações complexas.	Valores extremos podem distorcer significativamente a medida do erro absoluto médio em termos percentuais, especialmente em conjuntos de dados pequenos.
Penaliza os erros grandes de forma mais significativa do que erros menores, pois é uma medida do erro absoluto médio em termos percentuais	Dificuldade em comparar diretamente com outras métricas de avaliação, especialmente aquelas que não são baseadas em porcentagem
Fornecer uma medida direta da precisão das previsões em termos percentuais, tornando os resultados facilmente interpretáveis	Exige que os valores reais sejam estritamente positivos, pois ocorre divisão por zero quando os valores reais são iguais a zero.

Tabela 6.10: Vantagens e Desvantagens do MDAPE

6.8. Quando Usar o GMRAE

O Erro Percentual Absoluto Médio Geométrico (GMRAE), é uma métrica valiosa em situações onde a precisão de valores positivos ou de taxas de crescimento é crucial, e a estabilidade percentual das previsões é uma consideração importante. A Tabela-6.11 fornece de modo estruturado as indicações de uso.

Consideração de Uso	Descrição
Previsões de Valores Positivos	O GMRAE pode ser uma boa opção quando se está lidando com previsões de valores estritamente positivos, como demanda de produtos, tráfego da web e taxas de crescimento. O GMRAE é mais adequado para avaliar a precisão de previsões em situações em que valores negativos não fazem sentido, pois calcula a média geométrica dos erros percentuais.
Avaliação de Previsões de Taxas de Crescimento	Para priorizar a estabilidade percentual das previsões, o GMRAE pode ser mais adequado. Em comparação com métricas de erro absoluto, como o MAE, ele penaliza mais as variações percentuais grandes.
Modelagem de Séries Temporais	O GMRAE pode fornecer uma avaliação confiável e informativa da precisão do modelo em modelagem de séries temporais, especialmente para séries com valores estritamente positivos ou previsões de crescimento.
Robustez contra Valores Nulos	O GMRAE, assim como outras métricas de erro percentual, é resistente a valores nulos nos dados. Isso o torna adequado para conjuntos de dados onde há observações ausentes ou valores faltantes.

Tabela 6.11: Recomendação para o uso da métrica GMRAE

6.8.1. Vantagens e Desvantagens do GMRAE

Como consideração final, segue, de maneira estruturada, conforme apresentado na Tabela-6.12 as vantagens e desvantagens a serem observadas ao escolher esta abordagem:

Erro Percentual Absoluto Médio Geométrico (GMRAE)	
⊕ Vantagens	⊖ Desvantagens
Fornecer uma medida direta da precisão das previsões em termos percentuais.	Assim como outras métricas baseadas em porcentagem, o GMRAE exige que os valores reais sejam estritamente positivos.
Considera tanto a magnitude dos erros quanto o tamanho dos valores reais, proporcionando uma medida mais equilibrada da precisão das previsões	O cálculo pode ser mais complexo do que outras métricas, especialmente quando os conjuntos de dados são grandes.
Robusto a problemas de divisão por zero, pois adiciona uma constante suavizadora aos valores reais antes de calcular os erros relativos.	Sensível a valores extremos nos dados, especialmente quando os valores reais são muito pequenos.

Tabela 6.12: Vantagens e Desvantagens do GMRAE

6.9. Critério de Decisão entre MDAPE e GMARAE

Escolher entre MDAPE (Erro Percentual Absoluto Médio Direcional) ou o GMRAE (Erro Percentual Absoluto Médio Geométrico) para avaliar a precisão de modelos de previsão depende de vários fatores.

O fluxograma apresentado na Figura-6.3, estrutura um roteiro de perguntas, que auxilia a decisão de qual métrica utilizar.

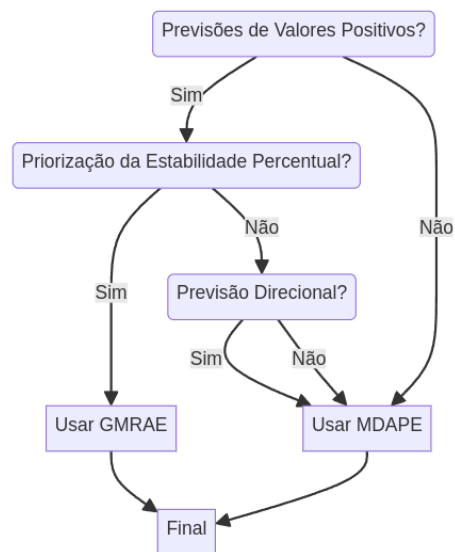


Figura 6.3: Critério de Decisão entre MDAPE e GMARAE

7

Conclusão

7.1. Resumo Geral

Cada métrica tem suas próprias vantagens e desvantagens, e a escolha deve estar em conformidade com os requisitos específicos da previsão, considerando as características dos dados, bem como a importância relativa dos aspectos de precisão.

Logo, utilizar múltiplas métricas é frequentemente recomendado para avaliar de forma abrangente o desempenho dos modelos de previsão. Principais pontos:

- **MAE (Erro Médio Absoluto) e RMSE (Erro Médio Quadrático)** são adequados para medir a magnitude dos erros e oferecem facilidade de interpretação.
- **MAPE (Erro Percentual Absoluto Médio) e SMAPE (Erro Percentual Absoluto Médio Simétrico)** são eficazes para expressar erros como porcentagens dos valores reais, facilitando a comparação do desempenho da previsão em diferentes conjuntos de dados.
- **MDAPE (Erro Percentual Absoluto Mediano)** é recomendado para dados de séries temporais propensos a valores extremos ou discrepantes, pois é robusto devido ao cálculo da mediana dos erros percentuais absolutos.
- **GMRAE (Erro Absoluto Relativo Médio Geométrico)** é útil ao comparar o desempenho da previsão em diferentes séries temporais com escalas variadas, fornecendo uma medida equilibrada de precisão.

7.1.1. Resultados Obtidos pelos Grupos de Desenvolvimento

Com base nos resultados obtidos pelos diferentes grupos, apresentados no Capítulo-5, foi realizado o cálculo de todas as métricas presentes neste estudo, e resumidos na Tabela-7.1.

Com base no Capítulo-4, onde todos os critérios de seleção são apresentados, concluímos que para este exemplo, a melhor métrica a ser utilizada é a MAE, devido a sua facilidade de interpretação e condições dos dados.

Modelo	MAE	RMSE	MAPE	SMAPE	MDAPE	GMRAE
XGB	383.867	696.768	2.16391	2.11816	0.00432114	0.0222393
Prophet	1336.81	1749.18	7.18719	7.40709	5.9377	5.12112

Tabela 7.1: Resultados das Métricas Calculadas